RESEARCH MANUSCRIPT

기본 동작 교정 기반 자세 보조 정확 용량 트랜스덕티브 sEMG 미관측 손 제스처 인식

NinaPro DB5에서 기본 손가락 동작과 손 펴기·쥐기 교정으로 미관측 Exercise-B 제스처를 인식하는 완전 대칭 대상자별 평가

출판 전 저자 확인용 최종 원고

2026-08-15

NinaPro DB5 자세 보조 미관측 제스처 원고

제목 페이지

저자: [저자명 입력]

소속: [소속 입력]

교신저자: [이름, 우편 주소, 이메일 입력]

축약 제목: 자세 보조 트랜스덕티브 미관측 제스처 인식

원고 유형: 원저

데이터셋: NinaPro Database 5(DB5)만 사용

초록

배경

표면 근전도(surface electromyography, sEMG) 기반 손 제스처 인식은 비침습적이고 착용형 장치에 적합하지만, 사람마다 다른 근활성 분포와 모든 제스처를 반복 수집해야 하는 교정 부담 때문에 새로운 사용자와 새로운 손 구성으로 일반화하기 어렵다. 자세 정보는 EMG와 제스처 의미를 연결하는 보조 의미 공간을 제공할 수 있지만, 평가 제스처의 타깃 EMG 라벨 없이 이 연결을 활용하는 방법과 그 정보 경계를 명확히 구분해야 한다.

목적

본 연구는 NinaPro DB5에서 타깃 대상자의 Exercise-A 기본 동작 12개와 Exercise-B 손 펴기·쥐기(B5/B6)만 교정한 뒤, 라벨된 타깃 예제가 없는 B1/B2/B3/B4/B7을 인식하는 Target-A 안정성 선택 파이프라인의 내부 성능을 평가했다.

방법

DB5의 s1–s10을 각각 한 번씩 타깃으로 두고, 매 fold에서 나머지 9명의 B1/B2/B3/B4/B7 글러브 자세를 의미 프로토타입으로 사용했다. 타깃 A1–A12+B5/B6 EMG와 글러브는 교정에 허용했지만, 평가 질의에서는 타깃 EMG만 입력했고 타깃 평가 글러브와 라벨은 예측 완료 전까지 접근하지 않았다. 2초 비중첩 윈도우에서 128차원 시간영역 EMG 특징과 66차원 자세 요약을 추출하고, 가중 RidgeCV로 EMG에서 자세를 예측했다. 세 EMG 뷰, 세 예측 자세 가중치, 세 강건 집계법으로 구성된 27개 후보를 12개 whole-class A holdout과 B5/B6 적격 조건으로 대상자별 선택했다. 최종 질의는 정확히 6개 trial을 갖는 5개 군집으로 분할하고, other-nine 자세 프로토타입과 헝가리안 일대일 할당으로 군집 이름을 정했다. trial 균형 정확도(BA)를 핵심 지표로 사용했다.

결과

최종 파이프라인의 s1–s10 평균 trial BA와 macro F1은 0.8733이었고 window BA는 0.8730이었다. 대상자별 trial BA 범위는 0.6000–1.0000이었으며 6명에서 1.0000을 기록했다. B1/B2/B3/B4/B7 재현율은 각각 1.0000, 0.7833, 0.7833, 0.9167, 0.8833이었다.

결론

자세 의미, 정확 클래스 용량, 전체 질의 배치를 사용하는 폐쇄형 트랜스덕티브 조건에서 미관측 B 제스처를 구분했다. 최종 파이프라인은 잠금 실행과 독립 재계산으로 재현됐지만, 동일 DB5 코호트의 이전 분석이 후보군 개발에 관여했으므로 0.8733은 독립 검증값이 아니라 내부 개발 성능이다. 본 결과는 온라인·귀납적 제로샷 인식이 아니라 자세 보조, 전체 배치, 정확 용량을 전제로 한 미관측 제스처 인식의 범위를 보여준다.

주요어: 표면 근전도, 손 제스처 인식, NinaPro DB5, 트랜스덕티브 학습, 제로샷 학습, 자세 의미, 균형 군집화, 대상자별 안정성 선택

1. 서론

표면 근전도는 피부 위에서 근육 활성의 전기적 표현을 비침습적으로 측정하며 상지 의수 제어의 입력으로 널리 연구되어 왔다[1,2]. 그러나 통제된 실험실에서 높은 분류 정확도를 얻더라도 실제 사용에서는 전극 위치, 피부-전극 접촉, 수축 강도, 자세, 세션과 사용자 차이가 신호 분포를 바꾼다[1,2]. 특히 여러 사용자의 EMG를 직접 합치거나 한 사용자에서 학습한 분류기를 다른 사용자에게 적용하면, 같은 동작이라도 채널별 진폭과 특징 관계가 달라질 수 있다. 그 결과 사용자마다 많은 라벨 예제를 다시 수집하는 교정 절차가 필요하다.

사용자 교정 부담을 줄이는 한 가지 방향은 소수의 기본 동작에서 관찰한 정보를 이용해 아직 라벨링하지 않은 복합 손 구성을 추론하는 것이다. 이때 EMG만으로 제스처 사이의 의미 관계를 학습하기는 어렵다. 반면 동기화된 손 자세는 어떤 손가락과 관절이 함께 움직이는지를 직접 표현하므로, EMG 표현을 제스처 의미와 연결하는 보조 모달리티가 될 수 있다. 최근 EMBridge는 EMG와 자세 masked autoencoder, Q-Former, 정확 짝 대조학습, 마스킹 자세 재구성, 자세 커뮤니티 구조를 결합해 미관측 제스처 일반화를 연구했다[5]. 이는 자세가 EMG 표현의 의미 구조를 조직할 수 있다는 근거를 제공하지만, 대규모 교차모달 신경망이 모든 데이터 규모와 평가 조건에서 최선이라는 뜻은 아니다.

본 연구는 같은 과학적 질문을 더 명시적인 구조화 파이프라인으로 다룬다. NinaPro DB5는 두 개의 Myo 암밴드에서 얻은 16채널 EMG와 22센서 CyberGlove 신호를 동기화해 제공하며, 10명의 온전한 상지 대상자가 52개 동작을 6회씩 수행했다[3,4]. 본 연구는 Exercise A의 기본 손가락 동작 A1–A12와 Exercise B의 손 펴기·쥐기 B5/B6을 타깃 교정에 사용하고, B1/B2/B3/B4/B7을 평가 제스처로 남겼다. 이 분할은 기본 동작과 두 가지 전체 손 자세에서 얻은 정보를 이용해 다른 다중 손가락 구성을 구분할 수 있는지를 묻는 조작적 설정이다. 모든 B 동작이 모든 A 동작보다 생리학적으로 더 복잡하다는 보편적 위계를 주장하지 않는다.

본 과제에는 두 가지 상호 보완적 문제가 있다. 첫째, 평가 제스처의 라벨된 타깃 EMG가 없어도 다른 대상자의 자세 의미와 타깃의 비라벨 EMG 구조를 결합할 수 있는가. 둘째, 하나의 고정 EMG 표현이 모든 사람에게 동일하게 적합하지 않을 때, 평가 정답을 보지 않고도 타깃의 허용된 기본 동작에서 안정적인 표현을 선택할 수 있는가. 이를 위해 본 연구는 EMG-자세 Ridge 브리지, 정확 용량 균형 군집화, other-nine 자세 프로토타입, 헝가리안 일대일 명명을 결합하고, 27개 고정 후보를 타깃 A whole-class holdout 안정성으로 선택했다.

본 연구의 기여는 다음과 같다. 첫째, s1–s10을 동일한 지위의 타깃 fold로 포함하고 각 fold에서 해당 타깃을 자세 donor에서 제외하는 완전 대칭 평가를 구성했다. 둘째, 타깃 평가 질의에서 EMG만 사용하면서도 다른 9명의 자세 의미와 비라벨 질의 배치를 결합하는 정보 경계를 명시했다. 셋째, 모든 대상자에게 동일하게 적용되는 안정성 기반

대상자별 후보 선택을 설계했다. 넷째, 평균 성능과 함께 모든 대상자 결과, 클래스별 재현율, 대상자-클래스별 오류 구조와 내부 개발 성능이라는 증거 경계를 함께 보고했다.

2. 관련 연구

2.1 sEMG 제스처 인식과 대상자 간 변이

고전적인 근전도 패턴 인식은 짧은 윈도우에서 평균 절대값, 파형 길이, 영교차와 기울기 부호 변화 같은 시간영역 특징을 추출하고 분류기에 입력한다[7]. 후보 EMG 특징 사이의 중복은 특징 축소와 선택 연구의 근거가 돼 왔다[8]. 여기에 알려진 사용자·측정 조건의 변이[1,2]를 고려하면, 하나의 특징 부분집합이 모든 대상자에게 최적이라고 가정하기보다 미리 정한 특징군을 비교할 필요가 있다.

DB5 원 논문은 동작과 대상자에 따라 EMG 진폭이 유의하게 달라질 수 있음을 보고했고, 두 Myo 암밴드 조건에서 손 동작 분류가 가능함을 검증했다[3]. 이러한 차이는 본 연구에서 각 타깃을 독립적인 분석 단위로 유지하고, 성능을 대상자 평균만으로 요약하지 않은 이유다.

2.2 자세를 이용한 교차모달 의미 연결

EMBridge는 먼저 EMG와 자세 인코더를 masked autoencoding으로 사전학습한 뒤, 동결된 자세 표현을 기준으로 Q-Former가 EMG에서 자세 관련 질의를 추출하도록 학습한다[5]. InfoNCE는 정확 EMG-자세 쌍을 정렬하고, masked pose reconstruction은 EMG 유래 질의에서 누락된 자세 토큰을 복원하며, community-aware soft contrastive learning은 자세 공간의 이웃 구조를 EMG-자세 유사도에 전달한다. 본 연구는 자세를 의미 앵커로 사용한다는 문제의식을 공유하지만, 해당 신경망 구성이나 손실을 사용하지 않는다. 대신 시간영역 EMG 특징, 선형 Ridge 브리지, 군집 구조와 자세 프로토타입을 분리해 각 정보가 예측에 어떻게 들어가는지 추적할 수 있게 했다.

2.3 트랜스덕티브 미관측 클래스 인식

제로샷 학습은 보조 데이터에서 얻은 의미 표현을 이용해 라벨 예제가 없는 타깃 클래스를 인식한다. 트랜스덕티브 제로샷 학습은 개별 질의를 독립적으로 처리하는 대신, 비라벨 타깃 질의 집합의 구조를 함께 이용할 수 있다[6]. 본 연구는 대상자당 30개 평가 trial 전체를 한 번에 군집화하므로 트랜스덕티브다. 또한 5개 클래스와 클래스당 6개 trial이라는 정확 용량을 알고 있다. 따라서 본 설정은 일반적인 온라인 또는 열린 목록 제로샷 분류보다 강한 사전정보를 사용하는 폐쇄형 전체 배치 문제다.

2.4 균형 군집화와 의미 명명

균형 k-means는 각 군집 크기를 미리 정하고 할당 문제를 풀어 군집 용량을 보장할 수 있다[10]. 본 연구는 클래스당 반복 수가 정확히 6이라는 DB5 프로토콜을 군집 용량으로 사용한다. 이후 익명 군집과 자세 클래스 프로토타입 사이의 점수행렬을 일대일 선형 할당으로 연결한다. 군집을 만드는 단계와 군집에 의미 이름을 붙이는 단계를 분리함으로써, 오류가 EMG 분리 실패인지 자세 명명 실패인지 부분적으로 진단할 수 있다.

3. 재료 및 방법

3.1 연구 설계

본 연구는 공개된 비식별 NinaPro DB5의 2차 계산 분석이다. s1-s10을 모두 포함하고 각 대상자를 한 번씩 타깃으로 두는 10-fold 완전 대칭 평가를 사용했다. 특정 대상자를 개발용 또는 최종용으로 제외하지 않았다. 매 fold에서 현재 타깃 한 명을 자세 donor에서 제외하고 나머지 9명을 donor로 사용했으며, 같은 규칙을 s1-s10 모두에 적용했다.

연구 목적은 타깃 A1-A12+B5/B6 교정, other-nine 자세 의미와 Target-A 안정성 선택을 결합한 최종 파이프라인의 B1/B2/B3/B4/B7 내부 인식 성능을 기술하는 것이다. 이 분석은 동일 DB5 코호트에서 방법 개발과 평가가 이뤄진 후향적 개발 연구이며 독립 외부 검증 연구가 아니다.



그림 1. 완전 대칭 대상자별 연구 설계와 정보 경계. 현재 타깃은 자세 donor 집합에서 제외된다. 후보 선택은 타깃 A1-A12+B5/B6과 다른 9명의 자세 의미만 사용한다. 타깃 B1/B2/B3/B4/B7 글러브와 라벨은 예측을 봉인한 뒤 평가에만 사용한다.

3.2 데이터셋과 운동 분할

DB5는 10명의 온전한 상지 대상자, 두 Myo 암밴드의 16채널 EMG(200 Hz), 22센서 CyberGlove, 52개 동작과 동작당 6회 반복을 포함한다[3,4]. 본 분석에서는 corrected movement label과 corrected repetition label을 사용했다.

NinaPro 동작 정의[3,4,12]에서 Exercise A는 A1 검지 굽힘, A2 검지 폄, A3 중지 굽힘, A4 중지 폄, A5 약지 굽힘, A6 약지 폄, A7 소지 굽힘, A8 소지 폄, A9 엄지 모음, A10 엄지 벌림, A11 엄지 굽힘, A12 엄지 폄이다. 본 연구에서 사용한 Exercise B는 B1 엄지 올리기, B2 검지·중지 폄과 나머지 손가락 굽힘, B3 약지·소지 굽힘과 나머지 손가락 폄, B4 엄지를 소지 기저부에 맞대기, B5 모든 손가락 벌리기, B6 손가락을 모아 주먹 쥐기, B7 검지 가리키기다. B5와 B6은 타깃 교정에 사용했고 B1-B4와 B7은 미관측 평가 클래스로 사용했다.

표 1. 본 연구의 데이터 역할과 정보 경계

데이터	사용 단계	역할
타깃 A1–A12 EMG와 글러브	교정·선택	전처리, Ridge 브리지, whole-class A holdout
타깃 B5/B6 EMG와 글러브	교정·선택	손 펴기·쥐기 교정, 대안 후보 적격 조건
other-nine A1–A12, B5/B6, B1/B2/B3/B4/B7 글러브	의미 참조	에피소드별 홀드아웃 클래스 자세 프로토타입
타깃 B1/B2/B3/B4/B7 EMG	평가 입력	라벨 없는 30-trial 질의 배치
타깃 평가 글러브와 라벨	결과 계산만	예측 해시 잠금 후 결과 계산
클래스 목록과 클래스당 6 trial	평가 사전정보	5개 정확 용량 군집과 일대일 명명
DB1, Exercise C, B8, B9–B17	사용하지 않음	본 원고의 선택·평가·주장 근거에서 제외

이 설정에서 평가 클래스의 타깃 EMG 라벨 예제는 0개다. 그러나 타깃 B5/B6의 EMG·글러브, other-nine 평가 클래스 글러브, 완전한 질의 배치와 정확 클래스 빈도를 사용한다. 그러므로 본 연구의 정확한 범위는 **타깃 교정 및 자세 보조 트랜스덕티브 미관측 제스처 인식**이다.

3.3 신호 전처리와 윈도우

0이 아닌 corrected movement 구간을 반복 단위로 분리하고 200 Hz에서 길이 2초, stride 2초의 비중첩 윈도우를 구성했다. 각 완전 윈도우는 EMG 16채널 x 400시점과 글러브 22센서 x 400시점으로 구성됐다. EMG에는 4차 Butterworth 2–95 Hz 대역통과 필터와 60 Hz notch 필터(Q=30)를 적용했다. 필터와 scaler는 허용된 교정 데이터 범위 안에서만 적합했다.

각 EMG 채널에서 평균 절대값(MAV), RMS, 표준편차, 최대-최소 진폭, 원시 파형 길이, 영교차율, 기울기 부호 변화율, 정규화 파형 길이를 계산해 총 128차원 특징을 만들었다. 이 구성은 고전적 시간영역 근전도 특징군[7,8]을 진폭, 변동, 복잡도와 부호 변화 관점에서 확장한 것이다.

각 글러브 센서에서는 윈도우 평균, 표준편차, 마지막 20% 평균과 처음 20% 평균의 차이를 계산해 66차원 자세 요약을 만들었다. 원시 글러브 값은 절대 관절각으로 교정된 값이 아니라 센서 출력이므로[4], 본 연구는 이를 대상자 간 상대적 자세 의미 기술자로 사용했다.

3.4 가중 Ridge EMG-자세 브리지

시간영역 EMG에서 자세 요약을 예측하기 위해 L_2 규제를 갖는 다출력 Ridge 회귀를 사용했다[9]. 타깃 교정 윈도우는 대상자 × exercise × class × repetition 그룹마다 총 가중치가 같도록 가중해 긴 구간이나 특정 클래스가 회귀를 지배하지 않게 했다. EMG와 자세 각각에 StandardScaler를 적합하고, 10^{-2}에서 10^{4}까지 로그 간격 13개 α 후보 중 RidgeCV가 선택했다.

$$J(B) = \Sigma_i \, w_i \, \| \, y_i - B^{\top} x_i \, \|_2^{\,2} + \alpha \, \| \, B \, \|_F^{\,2}$$

$$\hat{B} = \arg\min J(B)$$

여기서 x_i는 128차원 EMG 특징, y_i는 66차원 자세 요약, w_i는 그룹 균형 가중치다. 평가 시 실제 타깃 질의 글러브는 입력하지 않고 EMG에서 예측한 $\hat{y}_i$만 사용했다.

3.5 trial 표현과 균형 군집화

같은 trial에 속한 윈도우 특징을 평균해 trial 표현을 만들고 L2 정규화했다. 주 파이프라인과 안정성 후보에서 사용한 EMG 뷰는 다음과 같다.

- **MAV16:** 채널별 MAV 16개.
- **amplitude64:** MAV, RMS, 표준편차, 최대-최소 진폭의 64개.
- **all128:** 여덟 종류 시간영역 특징 전체 128개.

EMG trial 벡터 e_t와 EMG에서 예측한 자세 벡터 q_t는 자세 가중치 λ를 이용해 결합했다.

$$c_t = [e_t \; ; \; \sqrt{\lambda}\, q_t] \; / \; \sqrt{(1 + \lambda)}$$

대상자당 평가 trial 30개를 5개 군집으로 나누되 각 군집에 정확히 6개 trial이 들어가도록 했다. 각 초기 중심에 6개 slot을 만들고, 제곱 유클리드 거리를 비용으로 하는 선형 할당과 중심 갱신을 수렴할 때까지 반복했다. 이는 동일 크기 군집을 할당 문제로 푸는 균형 k-means 계열과 같은 원리다[10]. 결정적 k-means++ 초기화 64회 중 군집 내 제곱합이 가장 작은 해를 선택했다.

$$J(z, \mu) = \Sigma_t \; \| c_t - \mu(z_t) \|_2^2$$

$$(\hat{z}, \hat{\mu}) = \arg\min J(z, \mu)$$

제약조건: $\Sigma_t \, I(z_t = j) = 6, \;\; j \in \{1, \cdots, 5\}$

정확 용량 제약은 DB5의 동작당 6회 반복을 사용한다. 이는 성능에 기여하는 사전정보이며 실제 배치의 클래스 빈도를 모르는 상황으로 일반화할 수 없다.

3.6 자세 프로토타입과 군집 명명

각 타깃 fold에서 타깃을 제외한 9명의 B1/B2/B3/B4/B7 글러브 요약을 클래스별 평균해 66차원 자세 프로토타입을 만들었다. 평가 trial에서는 예측 자세와 다섯 프로토타입의 코사인 유사도를 계산했다. 익명 군집 안의 trial별 유사도를 평균해 5 × 5 군집-클래스 점수행렬을 만들고, 헝가리안 일대일 할당으로 각 군집에 서로 다른 클래스 이름을 부여했다[10].

고정 명명 규칙은 66차원 전체 자세 점수와 22개 윈도우 평균을 제외한 44차원 동적 자세 점수에서 각각 일대일 할당을 계산했다. 할당 마진은 최적 군집-클래스 순열의 총점에서 차선 순열의 총점을 뺀 값이다. 평가 예측 전에 고정한 규칙에 따라 s3-s6, s8, s10은 항상 전체 자세 명명을 사용했다. s1, s2, s7, s9는 전체 자세와 동적 자세의 매핑이 서로 다르고, 동적 마진이 더 크며, 전체 자세 마진이 0.08 미만일 때만 동적 명명으로 전환했다. Target-A 선택은 이 규칙을 다시 조정하지 않고 그대로 사용했다.

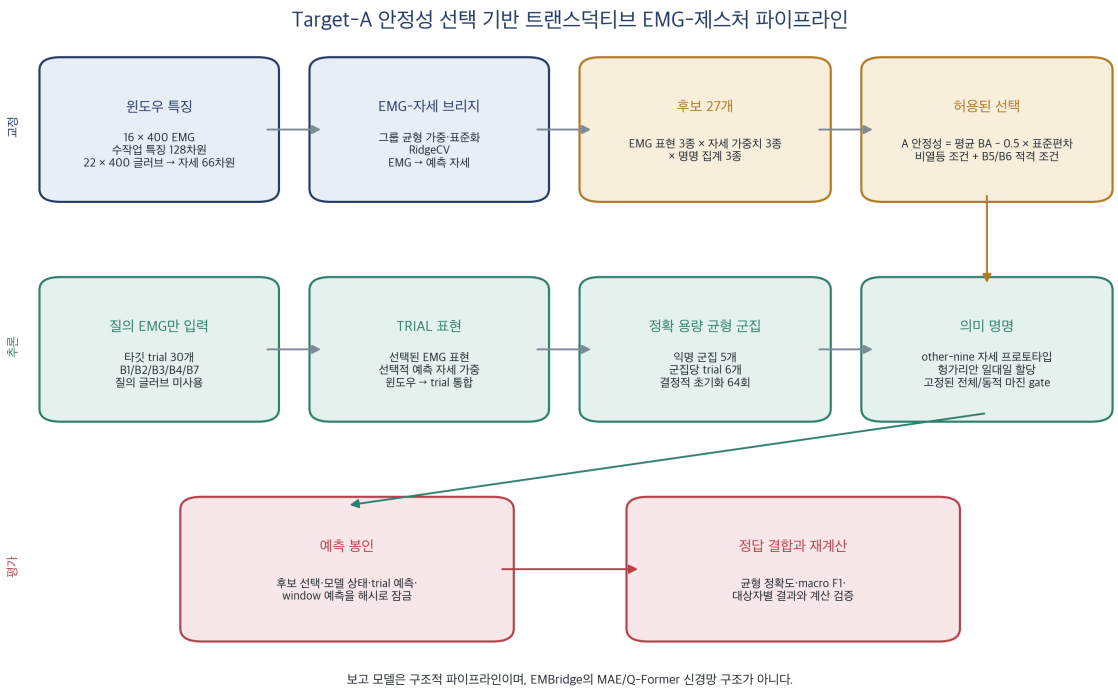


그림 2. 공통 대상자별 파이프라인. 모든 s1–s10 fold에 같은 후보군, 안정성 공식, 적격 조건과 평가 절차를 적용했다. 대상자별 허용 교정 데이터에 따라 최종 선택 결과는 달라질 수 있다.

3.7 Target-A 안정성 선택

하나의 고정 표현이 모든 사람에게 적합하지 않을 가능성을 평가하기 위해 다음 세 축을 완전 조합한 27개 후보를 정의했다.

1. EMG 군집 뷰: MAV16, amplitude64, all128.
2. 예측 자세 군집 가중치: 0, 0.25, 1.
3. 군집 내 자세 점수 집계: 평균, 중앙값, 양끝 하나씩 제거한 절사 평균.

Exercise-A 클래스는 같은 손가락 또는 운동축의 반대 방향을 묶어 A1/A2(검지 굽힘/폄), A3/A4(중지 굽힘/폄), A5/A6(약지 굽힘/폄), A7/A8(소지 굽힘/폄), A9/A10(엄지 모음/벌림), A11/A12(엄지 굽힘/폄)의 여섯 쌍으로 구성했다. 각 에피소드에서 한 쌍을 제외하고 나머지 다섯 쌍에서 교대로 하나씩 골라 5-class 질의를 만들었다. 제외 쌍 6개와 두 위상을 결합해 12개 whole-class A holdout 에피소드를 구성했다.

각 후보의 안정성 점수는 다음과 같이 계산했다.

$$\text{A 안정성}(m) = \text{mean}_{k}[\text{BA}(m,k)] - 0.5 \times \text{SD}_{k}[\text{BA}(m,k)], \quad k = 1, \cdots, 12$$

대안 후보는 다음 조건을 모두 만족할 때만 선택 가능했다.

1. 평균 A trial BA가 미리 고정된 기본 후보보다 0.005 초과 낮지 않을 것.
2. 알려진 B5/B6 trial BA가 0.80 이상일 것.

3. A 안정성이 기본 후보보다 0.02 이상 높을 것.

적격 후보는 안정성, 평균 A trial BA, 평균 A window BA, B5/B6 BA, 고정 후보 ID 순으로 정렬했다. 적격 대안이 없으면 기본 후보 자체의 B5/B6 BA가 0.80 미만이더라도 기본 후보를 유지했다. 즉, B5/B6 기준은 대안 선택을 제한하지만 최종 B5/B6 성능을 보증하지 않는다. 이 선택 규칙은 모든 대상자에게 동일했고 평가 B1/B2/B3/B4/B7 정답을 사용하지 않았다.

표 2. 에피소드별 적합 데이터, 질의와 자세 프로토타입 구성

에피소드	RidgeCV·scaler 타깃 적합 데이터	라벨 없이 예측하는 타깃 질의	other-nine 자세 프로토타입	사용 목적
12개 A 홀드아웃 중 하나	해당 에피소드 질의에 없는 A 7개 클래스와 B5/B6	홀드아웃 A 5개 클래스, 클래스당 6 trial	같은 A 5개 클래스; 각 donor는 해당 에피소드의 허용 적합 데이터로 스케일링	안정성·A 비열등 조건
B5/B6 에피소드	A1–A12 전체; 타깃 B5/B6은 적합에서 제외	B5와 B6, 클래스당 6 trial	donor B5/B6; 각 donor는 A 데이터로 스케일링	대안 적격 조건만 평가
최종 B 평가	타깃 A1–A12+B5/B6	B1/B2/B3/B4/B7, 클래스당 6 trial	donor B1/B2/B3/B4/B7	선택 잠금 후 예측

각 proxy 에피소드에서 RidgeCV와 모든 StandardScaler를 처음부터 다시 적합했다. 어떤 클래스가 에피소드 질의에 포함되면 그 클래스는 해당 에피소드의 타깃 적합 데이터에서 완전히 제외됐다. 최종 B 평가는 대상자별 선택을 잠근 뒤에만 실행했다.

3.8 정보 접근 통제와 재현성 검증

후보 선택 단계는 허용된 타깃 A1–A12+B5/B6, other-nine 자세 의미와 고정 명명 규칙만 읽도록 제한했다. 대상자별 선택 파일과 프로토콜을 SHA-256으로 잠근 뒤 별도 예측 단계에서 타깃 평가 EMG만 불러 trial 및 window 예측을 생성했다. 예측도 해시로 잠근 후 마지막 평가 단계에서만 정답에 접근했다.

독립 재계산은 다음을 확인했다.

- DB5 이외 데이터 경로가 사용되지 않았는가.
- s1–s10 모든 대상자 선택이 독립적으로 재현되는가.
- 선택, 프로토콜과 예측 해시가 잠금 기록과 일치하는가.
- 예측 코드가 정답 파일이나 평가기를 읽지 않는가.
- trial·window 예측이 잠금 파일과 일치하는가.
- 모든 대상자 trial BA와 전체 평균이 원시 예측에서 다시 계산되는가.

모든 검사가 통과했다.

3.9 평가 지표와 통계 분석

핵심 결과 지표는 클래스별 재현율 평균인 trial 균형 정확도였다[11]. 각 대상자에서 5개 클래스와 클래스당 6개 trial이 있으므로 trial 정확도와 BA는 수치상 같지만, 클래스별 해석을 유지하기 위해 BA를 사용했다. trial macro F1과

window BA를 보조 지표로 보고했다. 평가 집합은 300개 trial과 388개 비중첩 window로 구성됐다. window 예측은 각 trial의 최종 결정을 그 trial에 속한 모든 window에 전파해 계산했으므로, 독립적인 window 분류기의 출력이 아니라 trial 결정의 지속시간 가중 요약이다. 지표는 대상자별로 계산한 뒤 s1–s10을 동일 가중치로 평균했다.

성능은 대상자별 trial BA와 macro F1, 전체 평균, 대상자 범위와 클래스별 재현율로 기술했다. 각 타깃 fold가 서로 중첩되는 9명 donor bank를 사용하고 동일 DB5 코호트가 방법 개발에도 관여했으므로, 독립된 새 사용자 모집단에 대한 확증 신뢰구간이나 가설검정은 제시하지 않았다.

분석은 Python 3.12.8, NumPy 2.1.3, pandas 2.2.3, SciPy 1.15.1과 scikit-learn 1.8.0 환경에서 수행했다.

4. 결과

4.1 최종 코호트 및 대상자별 성능

최종 Target-A 안정성 선택 파이프라인의 s1–s10 평균 trial BA와 macro F1은 0.8733이었고 window BA는 0.8730이었다. 동일한 클래스 빈도에서 총 300개 trial 중 262개를 정확히 분류했다. 대상자별 trial BA 범위는 0.6000–1.0000이었으며 s2, s3, s5, s7, s8, s10의 6명은 30개 trial을 모두 정확히 분류했다.

표 3. s1–s10 대상자별 최종 trial 균형 정확도

타깃	최종 trial BA
s1	0.6000
s2	1.0000
s3	1.0000
s4	0.8667
s5	1.0000
s6	0.6000
s7	1.0000
s8	1.0000
s9	0.6667
s10	1.0000
평균	**0.8733**

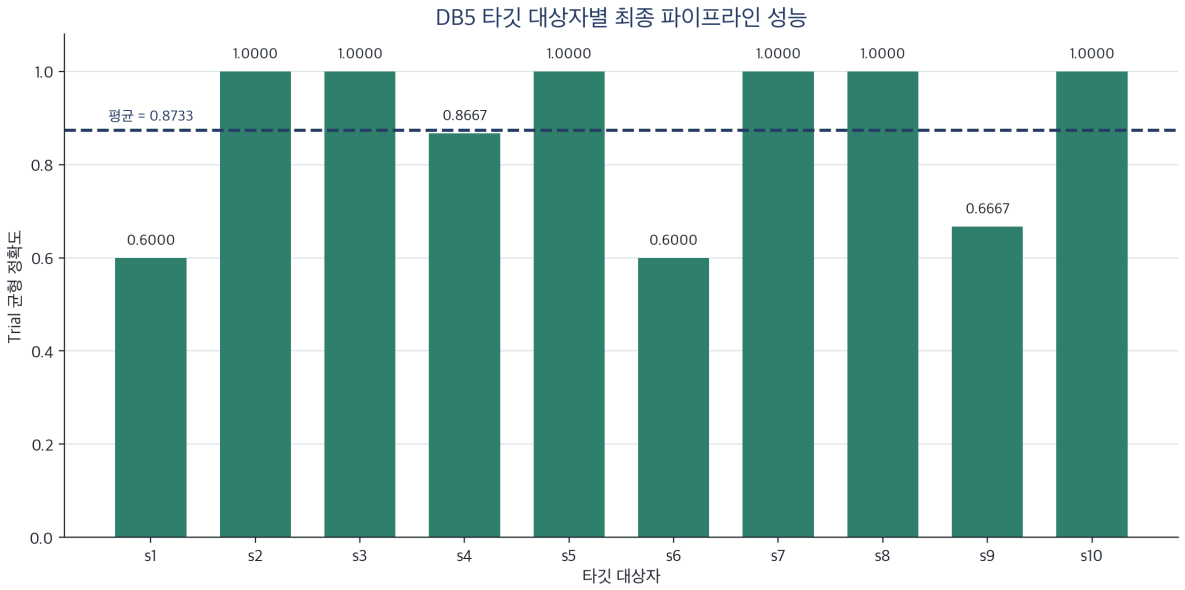


그림 3. 최종 파이프라인의 대상자별 trial 균형 정확도. 점선은 s1–s10 동일 가중 평균 0.8733을 나타낸다. 모든 대상자는 독립적인 타깃 fold로 동일하게 포함됐다.

4.2 Target-A 기반 대상자별 구성 선택

최종 선택은 대상자별 허용된 A1–A12+B5/B6 데이터에서만 계산됐다. amplitude64가 5명, all128이 4명, MAV16이 1명에서 선택됐다. 예측 자세를 군집 표현에 결합하지 않은 설정은 5명, 가중치 0.25는 3명, 가중치 1은 2명에서 선택됐다. 명명 집계는 평균이 7명, 중앙값이 2명, 절사 평균이 1명에서 선택됐다.

표 4. 대상자별 최종 선택 설정과 허용된 선택 지표

타깃	EMG 뷰	자세 가중치	명명 집계	A 안정성	평균 A trial BA	B5/B6 BA
s1	amplitude64	0	평균	0.3516	0.4361	1.0000
s2	MAV16	0	평균	0.4928	0.6250	0.0000
s3	all128	1	평균	0.5852	0.7306	1.0000
s4	all128	0.25	중앙값	0.2961	0.4028	1.0000
s5	all128	0.25	중앙값	0.4625	0.5667	1.0000
s6	amplitude64	1	평균	0.4579	0.5444	1.0000
s7	all128	0.25	절사 평균	0.5142	0.6333	1.0000
s8	amplitude64	0	평균	0.7311	0.8389	1.0000
s9	amplitude64	0	평균	0.3866	0.5667	1.0000
s10	amplitude64	0	평균	0.7709	0.8694	0.0000

동일한 all128 + 자세 0.25 + 중앙값 설정이 두 대상자에서 독립적으로 선택되는 등 최종 구성은 공통 후보군에서 반복 선택될 수 있었다. s2와 s10의 B5/B6 BA가 0.0000인 것은 B5/B6 0.80 조건이 적격 대안에만 적용되고, 적격 대안이 없을 때 유지되는 기본 후보의 성능을 보증하지 않기 때문이다.

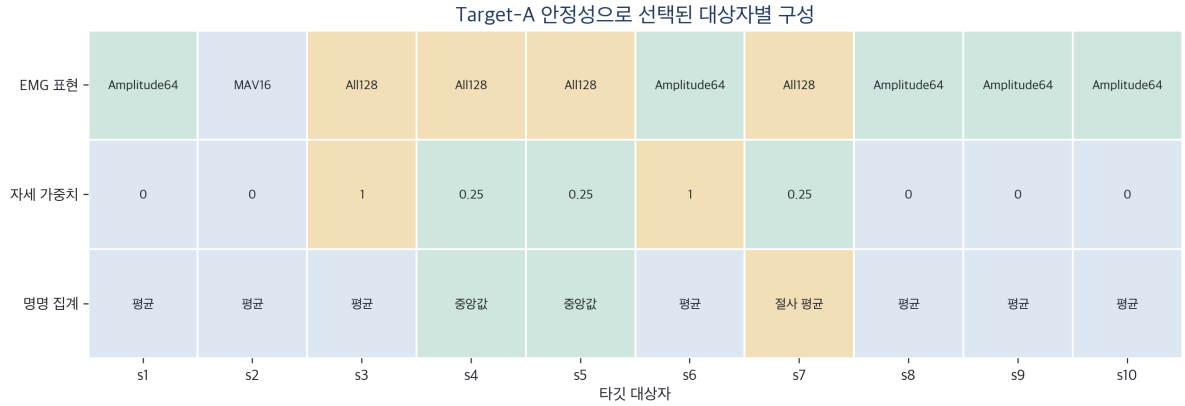


그림 4. Target-A 안정성으로 선택된 대상자별 최종 구성. 동일한 27개 후보와 선택 규칙을 모든 타깃에 적용했지만, 허용된 교정 데이터에 따라 EMG 뷰, 예측 자세 가중치와 명명 집계가 달라질 수 있다.

4.3 클래스별 결과와 대상자 간 오류 구조

최종 파이프라인의 전체 300개 trial에서 B1/B2/B3/B4/B7 재현율은 각각 1.0000, 0.7833, 0.7833, 0.9167, 0.8833이었다. 각 클래스는 60개 trial을 포함했다. B1은 60개 모두 정분류됐다. 주요 오류는 B2와 B3 사이의 상호 혼동, B3와 B7 사이의 혼동, B2와 B4 사이의 혼동이었다.

오류가 남은 대상자는 s1, s4, s6, s9의 네 명이었다. s1은 B3–B7, s4와 s9는 B2–B3, s6은 주로 B2–B4에서 상호 혼동을 보였다. 잔여 오류의 클래스 구조는 대상자에 따라 달랐다.

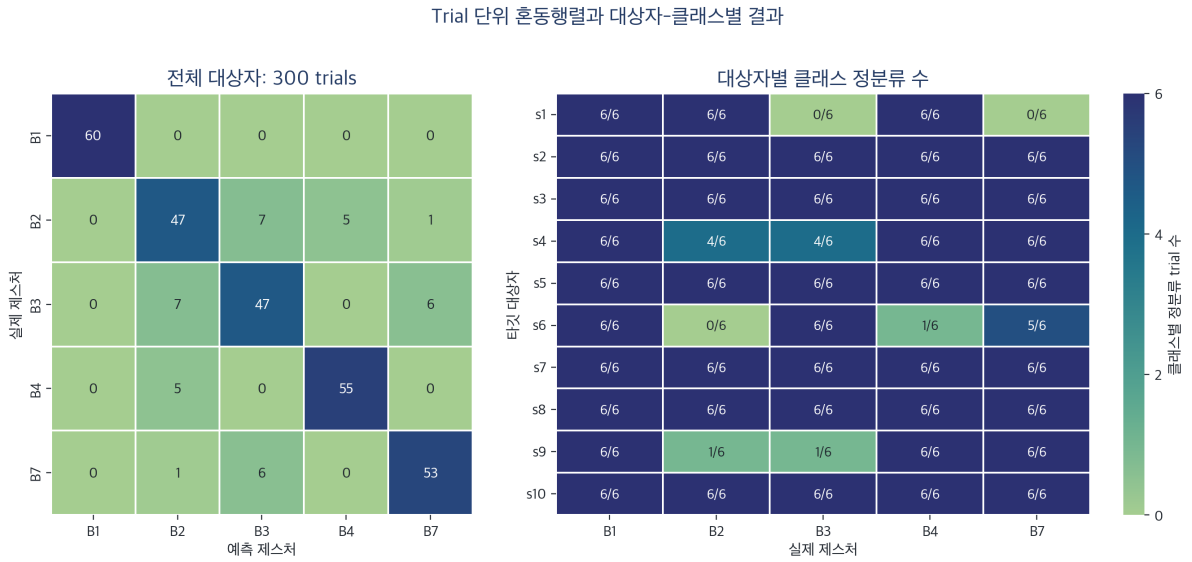


그림 5. 전체 코호트 혼동행렬과 대상자-클래스별 결과. 왼쪽의 모든 셀은 실제 클래스(행)와 예측 클래스(열)에 해당하는 전체 300개 trial의 수를 나타낸다. 오른쪽은 각 대상자와 실제 클래스에서 정분류한 trial 수를 정분류/6으로 표시한다.

4.4 내부 증거 상태와 계산 재현성

표 5. 최종 파이프라인의 성능 및 검증 요약

항목	관측값	해석
평균 trial BA	0.8733	s1–s10 동일 가중 평균
평균 trial macro F1	0.8733	대상자별 macro F1 평균
window BA	0.8730	trial 결정을 window에 전파한 지속시간 가중 요약
대상자별 trial BA 범위	0.6000–1.0000	대상자 간 변이 존재
완전 정분류 대상자	6/10	대상자당 30개 trial 모두 정분류
평가 규모	300 trial, 388 window	B1/B2/B3/B4/B7 전체
독립 계산 재실행	모든 검사 통과	선택, 잠금, 예측과 지표 재현
증거 상태	내부 개발 성능	독립 외부 검증 아님

대상자별 선택, 프로토콜과 예측 해시, 모든 대상자 BA 및 전체 평균의 독립 재계산은 모두 일치했다. 잠금 실행에서 평가 질의 라벨이나 글러브에 대한 직접 접근은 확인되지 않았다. 다만 같은 DB5 코호트의 이전 결과가 연구 프로그램과 후보군 설계에 관여했으므로 0.8733은 독립 검증값이 아니라 후향적 내부 개발 성능이다.

5. 논의

5.1 주요 발견

본 연구는 타깃 A1-A12+B5/B6 교정과 other-nine 자세 의미를 이용한 폐쇄형 전체 배치 조건에서 미관측 B1/B2/B3/B4/B7을 평가했다. 공통 Target-A 안정성 선택 규칙을 포함한 최종 파이프라인은 s1-s10 평균 trial BA와 macro F1 0.8733, window BA 0.8730을 기록했다. 대상자별 BA는 0.6000-1.0000이었고 6명은 모든 평가 trial을 정확히 분류했다.

27개 후보와 선택 기준은 모든 s1-s10에 동일했다. 각 대상자는 자신의 허용된 A+B5/B6 데이터에서 후보를 선택했기 때문에 최종 설정은 대상자마다 달라질 수 있었으며, 같은 설정이 여러 대상자에서 반복 선택되기도 했다. 따라서 본 결과는 하나의 고정 표현이 아니라 **공통 적응 규칙이 대상자별 표현을 선택하는 파이프라인**의 결과다.

5.2 대상자 간 변이와 잔여 오류

대상자별 BA는 0.6000-1.0000으로 달랐다. 여섯 대상자는 완전 정분류됐고, 나머지 네 대상자의 오류 쌍은 동일하지 않았다. 따라서 코호트 평균과 함께 대상자별 성능 분포와 클래스별 오류 구조를 보고하는 것이 필요하다.

그러나 이러한 기술적 차이만으로 대상자 간 생리학적 또는 측정 원인을 확정할 수 없다. 전극 접촉, 근활성 전략, 반복 간 변동과 동작 수행 차이는 본 데이터와 분석만으로 분리할 수 없으며, 원인 규명에는 별도 신호 품질 및 실험 측정이 필요하다.

5.3 자세 의미와 구조적 파이프라인의 역할

본 파이프라인에서 자세는 세 지점에 관여한다. 첫째, 타깃 A+B5/B6에서 Ridge 브리지가 EMG-자세 대응을 학습한다. 둘째, other-nine 평가 클래스 자세가 익명 군집을 B1/B2/B3/B4/B7로 이름 붙이는 의미 프로토타입이 된다. 셋째, 일부 후보에서는 예측 자세가 EMG 군집 표현에 약하게 결합된다. 반면 타깃 평가 질의의 실제 자세는 사용하지 않는다.

이 구조는 EMBridge가 제안한 "자세로 EMG 의미를 조직한다"는 큰 방향과 일치하지만 구현과 증거는 다르다[5]. EMBridge는 학습된 MAE, Q-Former와 대조·재구성 손실을 이용한다. 본 연구는 수작업 특징, 선형 브리지, 제한 군집, 프로토타입과 명시적 중간 점수를 사용한다. 따라서 본 결과를 EMBridge 재현이나 EMBridge 신경망 성능으로 표현해서는 안 되며, 별도의 구조적 방법으로 기술해야 한다. 실행시간, 파라미터 수, 메모리 또는 형식적 해석 가능성은 EMBridge와 비교하지 않았다.

5.4 제로샷 주장과 정보 경계

평가 클래스 B1/B2/B3/B4/B7의 라벨된 타깃 EMG가 학습에 들어가지 않았다는 점에서는 zero-EMG-shot 요소가 있다. 그러나 일반적인 귀납적 제로샷보다 더 많은 정보를 사용한다. 다른 대상자의 평가 클래스 글러브 자세, 알려진 5-class 목록, 대상자당 전체 30-trial 질의, 클래스당 정확히 6개라는 빈도 정보를 이용한다. 질의를 개별적으로 실시간 처리하지도 않는다.

따라서 가장 정확한 설명은 **자세 보조 트랜스덕티브 폐쇄형 미관측 제스처 인식**이다. 이 경계를 명시하면 높은 정확도를 과소평가하지 않으면서도, 정보가 더 제한된 온라인 배치나 클래스 빈도를 모르는 상황으로 결과를 과도하게 일반화하는 것을 막을 수 있다.

5.5 내부 개발 성능의 해석

잠금된 안정성 선택 실행에서는 평가 정답을 사용하지 않았고 예측을 해시로 먼저 잠갔다. 그 실행에서 직접적인 테스트 레이블 누출은 확인되지 않았다. 그럼에도 후보군과 안정성 가설은 이전에 같은 DB5 결과를 관찰한 뒤 설계됐다. 실행 수준의 정보 접근 통제는 연구 수준의 개발 노출을 되돌릴 수 없다.

따라서 0.8733은 최종 파이프라인이 현재 DB5 코호트에서 보인 재현 가능한 내부 성능을 기술한다. 그러나 새로운 사용자나 세션에서 기대되는 성능을 독립적으로 추정하지 않으며, 후보군을 사전에 고정한 새 데이터 평가가 필요하다. 이는 최종 파이프라인의 절차적 재현성과 성능 추정치의 외부 타당성을 구분하는 해석이다.

5.6 한계

첫째, DB5의 온전한 상지 대상자 10명만 분석했으며 모든 대상자가 방법 개발 과정에 노출됐다. 둘째, 정확 용량 군집화는 클래스당 6개 trial이라는 강한 사전정보를 사용한다. 셋째, 전체 배치 트랜스덕티브 추론이므로 온라인 또는 한 trial씩 도착하는 환경을 검증하지 않았다. 넷째, 평가 타깃 질의에는 EMG만 들어가지만 교정에는 타깃 B5/B6 글러브가, 의미 명명에는 other-nine 평가 클래스 글러브가 필요하다. 다섯째, A-to-B 분할은 본 연구의 조작적 의미 분할이지 동작 복잡도의 보편적 생리학적 서열이 아니다. 여섯째, 안정성 후보군과 대상자별 기본 후보는 연구 과정에서 후향적으로 정의됐으며 새로운 대상자에 대한 기본 후보 결정 규칙은 아직 외부 검증되지 않았다. 일곱째, 절단자, 임상 사용자, 다른 장치, 세션 간 변화, 전극 이동, 실시간 지연, 불균형 빈도, 알려지지 않은 클래스 빈도와 열린 집합 거부를 평가하지 않았다. 여덟째, fold들이 서로 중첩되는 other-nine donor bank를 사용하므로 대상자 결과는 완전히 독립된 모집단 표본이 아니다.

5.7 후속 확증 연구

후속 연구에서는 현재의 27개 후보, 안정성 공식, 세 적격 기준, 할당 마진 규칙, 지표와 실패 기준을 코드 해시와 함께 먼저 고정해야 한다. 이후 방법 설계 과정에서 결과를 한 번도 보지 않은 새로운 대상자 또는 새로운 수집 세션에서 예측을 잠근 뒤 한 번만 정답에 접근해야 한다. 현재 DB5 s1-s10은 모두 반복 개발에 사용됐으므로 기존 대상자를 다시 LOSO하는 것만으로 완전한 외부 확인이 되지는 않는다.

실용성 평가를 위해서는 정확 클래스 빈도를 모르는 불균형 배치, 일부 클래스만 존재하는 배치, 순차적 온라인 질의, donor 수 감소, target B5/B6 글러브 제거, 세션 간 변화와 latency를 별도 평가해야 한다. 성공 여부는 평균 BA뿐 아니라 대상자별 최저 성능, 클래스별 재현율과 대상자-클래스별 오류 구조로 판단해야 한다.

6. 결론

NinaPro DB5 s1-s10을 동일한 타깃 fold로 평가한 결과, 타깃 A1-A12+B5/B6 교정, Target-A 안정성 선택, other-nine 자세 프로토타입과 정확 용량 균형 군집화를 결합한 최종 파이프라인은 미관측 B1/B2/B3/B4/B7에서 평균 trial BA 0.8733을 기록했다. 평가 질의에서는 타깃 EMG만 사용했고, 모든 셀의 trial 수를 포함한 혼동행렬과 대상자별 결과를 함께 보고했다. 이 수치는 동일 DB5 코호트에서 개발되고 재실행된 내부 성능이며 독립 외부 검증값은 아니다. 온라인, 알려지지 않은 클래스 빈도와 새로운 대상자·세션에서의 성능은 별도 연구가 필요하다.

선언

윤리 승인과 동의

본 연구는 공개된 비식별 NinaPro DB5의 2차 분석이며 새로운 참가자를 모집하거나 추가 신호를 수집하지 않았다. 원 데이터 수집의 윤리 승인과 동의 문구는 데이터셋 원 논문[3]과 제출 기관의 요구사항을 책임 저자가 직접 확인해야 한다.

연구비

[저자 확인 필요: 실제 연구비, 과제번호와 지원기관의 역할 입력]

이해상충

[저자 확인 필요: 모든 저자의 실제 이해상충 선언 입력]

저자 기여

[저자 확인 필요: 저자 순서 확정 후 CRediT 역할 입력]

데이터 및 코드 가용성

원 NinaPro DB5 데이터는 Zenodo 데이터 레코드[4]의 배포 조건을 따른다. 분석 코드, 프로토콜 해시와 파생 비식별 결과의 공개 저장소는 [저장소 URL/DOI 입력]에 명시할 예정이다. 제출 전 책임 저자가 실제 공개 범위와 재실행 지침을 확인해야 한다.

인공지능 보조 사용

OpenAI Codex는 로컬 분석 실행 보조, 결과 provenance 정리, 그림 및 원고 초안 작성과 문서 형식화에 사용됐다. 도구는 저자로 등재되지 않으며, 모든 인간 저자가 수치, 코드, 해석, 인용, 저자 자격과 최종 문구에 책임을 진다. 이 문구는 제출 학술지의 최신 정책에 맞게 수정해야 한다.

참고문헌

1. Scheme E, Englehart K. Electromyogram pattern recognition for control of powered upper-limb prostheses: state of the art and challenges for clinical use. J Rehabil Res Dev. 2011;48(6):643–659. doi:10.1682/JRRD.2010.09.0177.

2. Farina D, Jiang N, Rehbaum H, Holobar A, Graimann B, Dietl H, Aszmann OC. The extraction of neural information from the surface EMG for the control of upper-limb prostheses: emerging avenues and challenges. IEEE Trans Neural Syst Rehabil Eng. 2014;22(4):797–809. doi:10.1109/TNSRE.2014.2305111.

3. Pizzolato S, Tagliapietra L, Cognolato M, Reggiani M, Müller H, Atzori M. Comparison of six electromyography acquisition setups on hand movement classification tasks. PLoS One. 2017;12(10):e0186132. doi:10.1371/journal.pone.0186132.

4. Pizzolato S, Tagliapietra L, Cognolato M, Reggiani M, Müller H, Atzori M. Ninapro dataset 5 (double Myo armband). Zenodo; 2017. doi:10.5281/zenodo.1000116.

5. Cui W, Sandino CM, Pouransari H, Liu R, Minxha J, Zippi EL, Azemi E, Mahasseni B. EMBridge: Enhancing Gesture Generalization from EMG Signals Through Cross-Modal Representation Learning. International Conference on Learning Representations. 2026. OpenReview: https://openreview.net/forum?id=LqrWNdceum.

6. Fu Y, Hospedales TM, Xiang T, Gong S. Transductive multi-view zero-shot learning. IEEE Trans Pattern Anal Mach Intell. 2015;37(11):2332–2345. doi:10.1109/TPAMI.2015.2408354.

7. Hudgins B, Parker P, Scott RN. A new strategy for multifunction myoelectric control. IEEE Trans Biomed Eng. 1993;40(1):82–94. doi:10.1109/10.204774.

8. Phinyomark A, Phukpattaranont P, Limsakul C. Feature reduction and selection for EMG signal classification. Expert Syst Appl. 2012;39(8):7420–7431. doi:10.1016/j.eswa.2012.01.102.

9. Hoerl AE, Kennard RW. Ridge regression: biased estimation for nonorthogonal problems. Technometrics. 1970;12(1):55–67. doi:10.1080/00401706.1970.10488634.

10. Malinen MI, Fränti P. Balanced K-means for clustering. In: Structural, Syntactic, and Statistical Pattern Recognition. Lecture Notes in Computer Science, vol 8621. Springer; 2014:32–41. doi:10.1007/978-3-662-44415-3_4.

11. Brodersen KH, Ong CS, Stephan KE, Buhmann JM. The balanced accuracy and its posterior distribution. In: 2010 20th International Conference on Pattern Recognition. IEEE; 2010:3121–3124. doi:10.1109/ICPR.2010.764.

12. Atzori M, Gijsberts A, Kuzborskij I, Elsig S, Mittaz Hager AG, Deriaz O, Castellini C, Müller H, Caputo B. Characterization of a benchmark database for myoelectric movement classification. IEEE Trans Neural Syst Rehabil Eng. 2015;23(1):73–83. doi:10.1109/TNSRE.2014.2328495.

제출 전 책임 저자 확인 항목

1. 저자명, 소속, 교신저자와 CRediT 역할을 실제 기여에 따라 확정한다.
2. 데이터셋 원 논문의 윤리 승인·동의 문구와 소속기관의 2차 분석 요구사항을 확인한다.
3. 연구비, 이해상충, 데이터·코드 공개 범위와 저장소를 실제 정보로 완성한다.
4. 목표 학술지의 현재 원고 형식, 단어 수, 표·그림, 참고문헌과 AI 사용 공개 정책을 적용한다.
5. 0.8733을 동일 DB5 코호트에서 얻은 내부 개발 성능으로 표현하고 독립 외부 확증값으로 표현하지 않는다.
6. 제출 승인 전 인간 저자가 모든 수치, 그림, 인용과 원문 지지 관계를 직접 확인한다.